

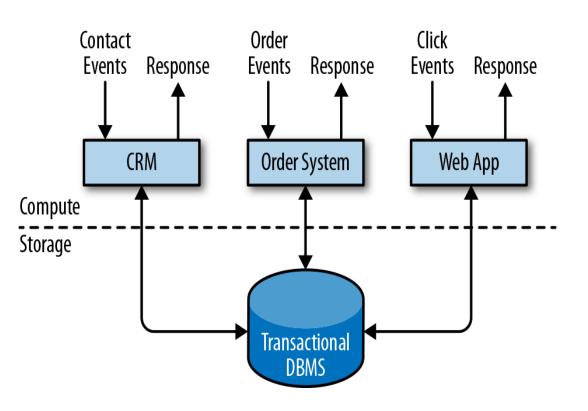




Plan du cours

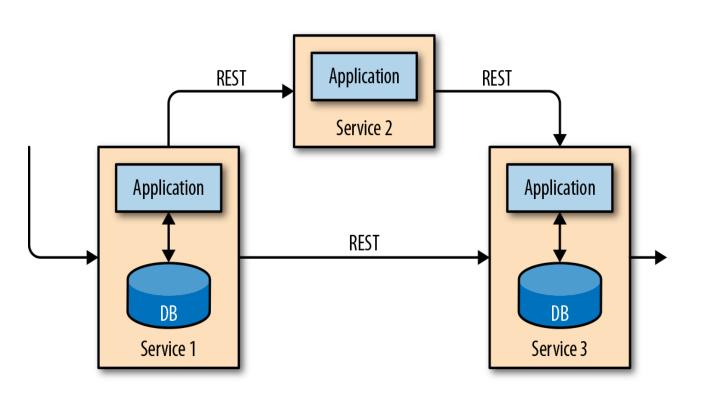
- I. Introduction au Stream
 - Les infrastructures traditionnelles
 - Le Stream Processing
- 2. Stream/Batch
 - Batch
 - Comparaison avec le Batch
 - Cas d'usages (particularités du Stream : fenêtre de calcul) Avantages/inconvénients
- 3. Les différents outils du Stream
 - Flink / Amazon / Google
 - Comment choisir ?
 - Tableau comparatif
- 4. Focus sur Flink avec une démo

Infrastructures traditionnelles: Transactionnal Processing



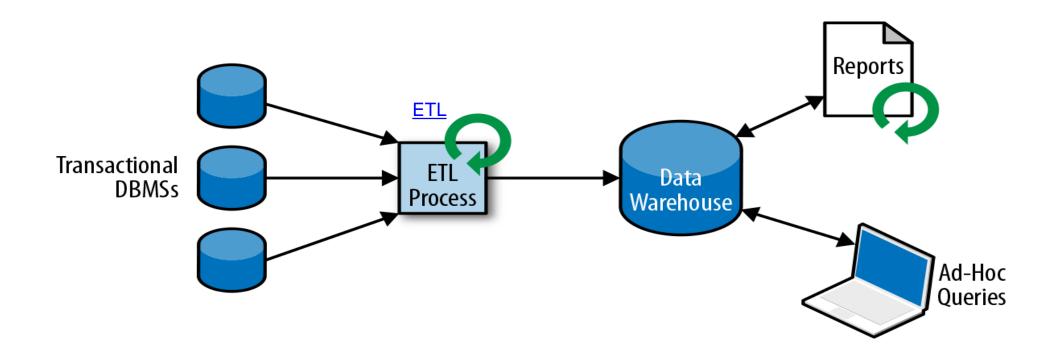
- Les applications sont connectées à des services externes et analyse continuellement des informations.
- Quand un évènement est analysé l'application interagit avec le système de stockage
- Un même DBMS sert plusieurs applications
- Problématique pour l'évolution et la scalability => Microservice

Infrastructures traditionnelles: Transactionnal Processing



- Les microservices sont de petites applications indépendantes
- On construit des applications plus complexes en interconnectant plusieurs microservices
- Ils sont déployés sur différents conteneurs et possèdent chacun leur propre technologie

Infrastructures traditionnelles: Analytical Processing



- Les données sont stockées dans différentes bases de données transactionnelles
- · Les données sont répliquées dans la Data Warehouse où elles seront requêtées (Batch)
- 2 types de requêtes :
 - Rapports périodiques
 - Requêtes ad hoc

Le Stream Processing: Stateless/Statefull

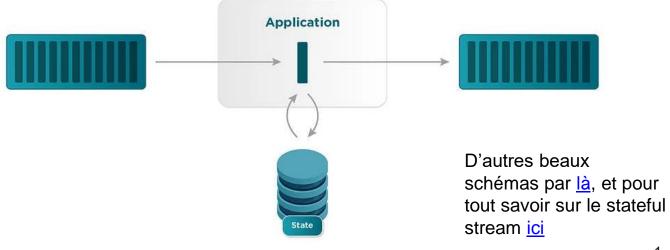
Stateless Stream Processing

La façon dont est analysé chaque évènement est indépendante des évènements précédents

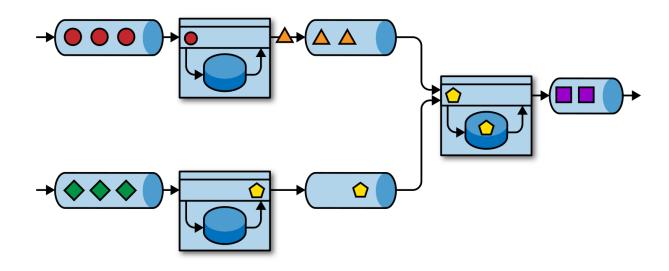
State: information conservée pour un usage futur, un contexte

Stateful Stream Processing

Un *state/contexte* est conservé entre les évènements. Les évènements précédents peuvent influer sur l'analyse des suivants.



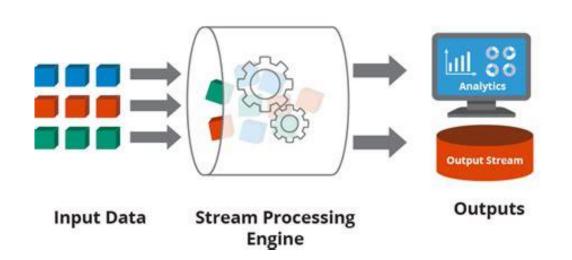
Le Stream Processing: Event-Driven application



Event logs = un broker

- Evolution des microservices
- Les applications communiquent entre elles via des event Logs
- Stockage dans des local state
- Chaque application est stateful et gère localement son state
- Une application peut être scale localement

Le Stream Processing



"Stream processing is a programming paradigm defining applications which, when receiving a sequence of data, treat it as a collection of elements, or datapoints, and rather than group and process them together, process each datapoint by itself"

- Les applications réagissent aux évènements instantanément
- Permet de gérer un grand volume de données
- Adapté aux time series et aux données continues
- Décentralise l'infrastructure

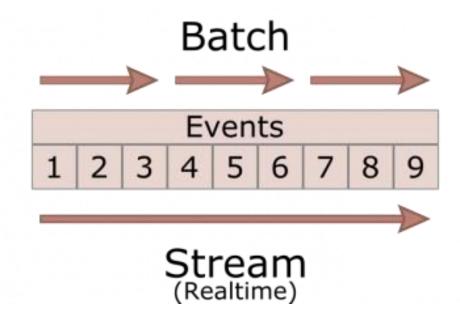
Batch ou Stream?

La définition de nos **besoins** définit quelle méthode va être utilisée.

Le **Batch** permet de traiter une **large quantité de données**, l'architecture est simple à mettre en place. Ce système comporte une **grande latence** des données.

Le **Stream** traite les données en **temps-réel**, l'architecture est plus complexe mais permet d'avoir une **faible latence** et donc un traitement en live.

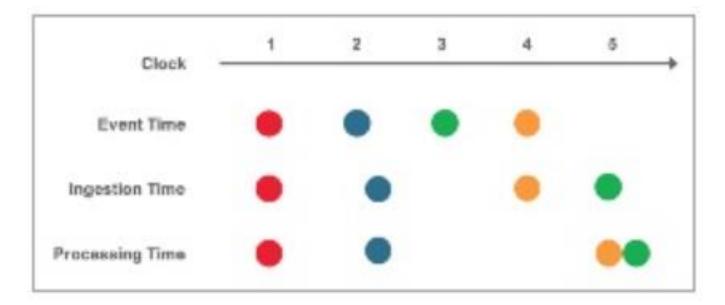
Data Processing Model



Le temps

Le **timestamp** définit la variable de **temps** d'une donnée.

- Event time : définit par l'évènement, dépendant de la donnée.
- Ingestion time : définit quand la donnée est ingérée dans le système.
- **Processing time** : définit quand la donnée est traitée.



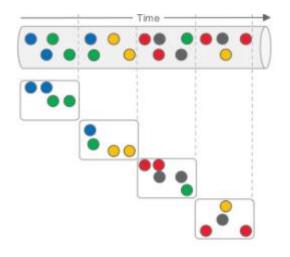
Cf slides 27 à 30 ici.

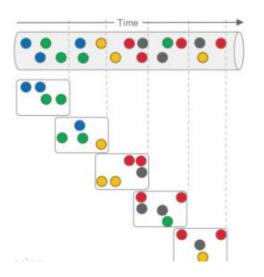
Stream Processing Window

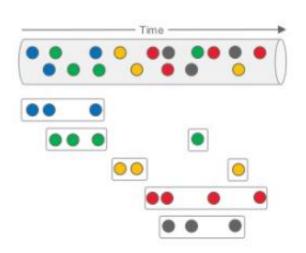
Les fenêtres permettent de compartimenter les données pour éviter des problèmes de mémoire du processeur.

Plusieurs types de fenêtres existent :

- Fixed window : fenêtres de même taille et pas d'enchevêtrement.
- Sliding window : fenêtres de même taille et une durée d'intervalle de glissement (< durée d'une fenêtre).
- Session Window: fenêtres de tailles différentes et définies par des identifiants de session.





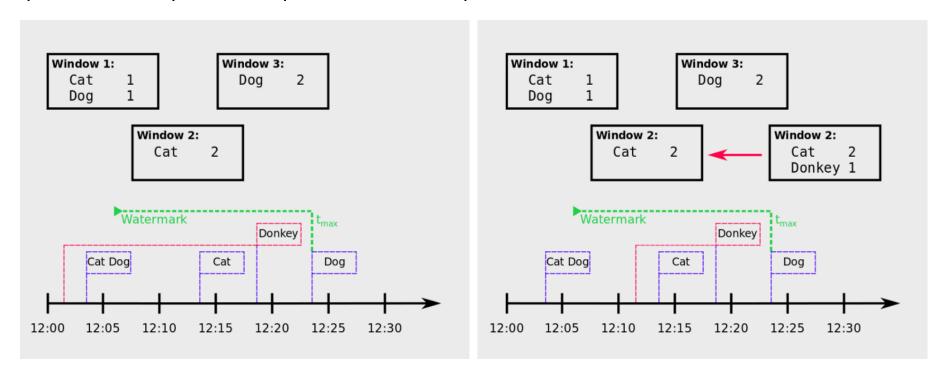


Watermarks

Un watermark est un outil qui permet de définir quand tous les évènements qui le précèdent sont considérés comme acquis.

Il permet de répondre au **retard** qu'un système de stream processing peut avoir.

Il est défini par une durée pendant laquelle les données peuvent encore arrivées.



Cf <u>ici</u> pour plus d'informations.

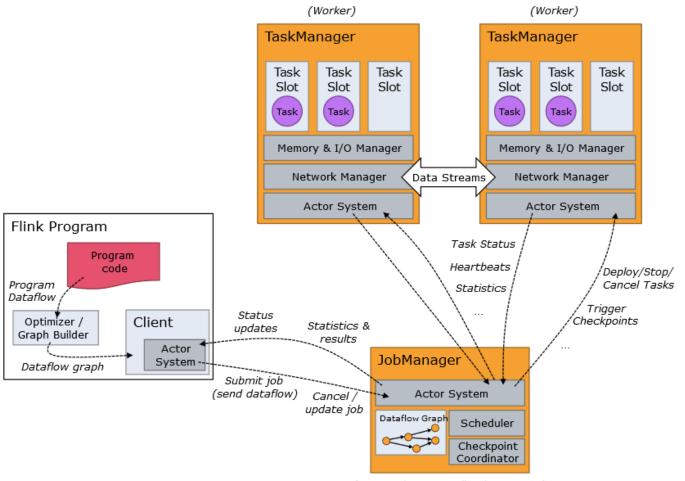
Triggers

Un trigger permet de déclencher le calcul le résultat final de la fenêtre.

- Watermark progress : calcul le résultat final de la fenêtre quand le watemark dépasse les limites d'une fenêtre.
- Event time progress : calcul les résultats des fenêtres plusieurs fois, avec un interval spécifique, au fur et à mesure que le watermark avance.
- Processing time progress: calcul les résultats des fenêtres plusieurs fois, avec un interval spécifique mesuré par rapport au temps de calcul.
- Punctuations : dépend de la donnée.

Open source : La Suite Apache

Apache Flink Architecture





Architecture Maître esclave

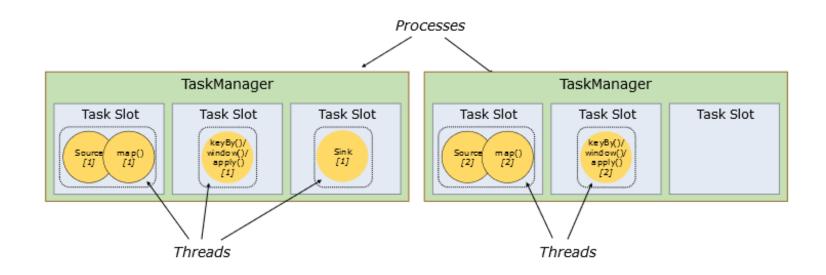
Un JobManager, planifie les tâches

Les TaskManagers, exécutent les tâches

(Master / YARN Application Master)

https://flink.apache.org/

Apache Flink



- Le Task Slot : un espace mémoire isolé dédié à l'exécution des *Threads*
- Un TaskManager peut avoir un ou plusieurs Task slots.
- Différente façon de déployer Flink (standalone, Docker...)

Amazon Kinesis



Avantages

- Puissance de traitement en temps réel
- · Aucun serveur à gérer
- Paiement en fonction de l'utilisation

Cas d'utilisation

- ETL de streaming
- Analytique en temps réel
- Traitement dynamique des événements

Google Dataflow



Avantages

Analyse rapide des flux de données

Opérations et gestion simplifiées

Réduction du coût total de possession

Cas d'utilisation

 IA en temps réel : Détection d'anomalies / Reconnaissance de formes / Prévisions de prédiction

 Traitement des données de capteurs et de journaux

https://cloud.google.com

Comment choisir?

Quels Avantages des données diffusées en continu ?

Quel coût et budget ?

Exemples de données diffusées en continu : Une société d'énergie solaire / Une société de jeux en ligne / Un établissement financier

Tableau comparatif: IT Central Station



https://www.itcentralstation.com

Apache Flink

https://www.itcentralstation.com/product_r eviews/apache-flink-review-120830-byrahul-agarwal?tid=pdf_cat_2612

Amazon Kinesis

https://www.itcentralstation.com/produc t_reviews/amazon-kinesis-review-123196-by-pabloginer?tid=pdf_cat_2612

Google dataflow

https://www.itcentralstation.com/p roducts/comparisons/apachenifi_vs_google-clouddataflow?tid=pdf_cat_2612

Focus sur Flink avec une démo

- · Téléchargement de la dernière version bin de flink : ici
- Changement du port de flink : <rootFlink>/conf/flink-conf.yaml
 - Rest.port: <numero du port>
- Démarrage de flink : <flink-home>/bin/start-cluster.sh
- Lancement du fichier : <flink-home>/bin/flink run <javaClass>.jar --input <wordInput.txt> -output <outputText>
- Regarder les logs : cat <outputText>
- tutoriel utilisé